Belief Propagation for Human Problem Solving

Changelog

- v0.1 —Initial draft created (2026 年 3 月 26 日).

1 Ideas & Framework

This project proposes a computational–neuroscientific investigation of how humans solve constraint satisfaction problems (CSPs), such as Sudoku or map-coloring, through local, iterative reasoning processes analogous to **Belief Propagation (BP)** algorithms.

We hypothesize that individual behavioral patterns—and their associated neural dynamics—correspond to distinct **scheduling strategies** in BP, yielding characteristic convergence profiles observable in neural data.

1.1 Scientific Question

1.1.1 Scientific Question 1: Local vs. Structured Inference

Let $G = (V, E)$ be a graph, X_i the target node to be reported, O the set of observed nodes, and $H \setminus i$ the remaining unobserved nodes. We assume a standard pairwise graphical model:

$$P(x_V) \propto \prod_{(u,v)\in E} \psi_{uv}(x_u, x_v) \prod_{u\in V} \phi_u(x_u).$$

We contrast two hypotheses about human probabilistic inference.

H0: Local independent inference. Participants estimate X_i using only its locally observed neighbors $O_i = N(i) \cap O$:

$$P_{\text{ind}}(x_i \mid x_O) = P(x_i \mid x_{O_i}) \propto \phi_i(x_i) \prod_{j\in O_i} \psi_{ij}(x_i, x_j).$$

Under this hypothesis, if the local observed neighborhood of X_i is held fixed, then changing distal structure or distal evidence should not affect the reported belief:

$$P^{(A)}_{\text{ind}}(x_i \mid x_O) = P^{(B)}_{\text{ind}}(x_i \mid x_O).$$

H1: Structured graph inference. Participants integrate over other unobserved variables, so the posterior of X_i depends on the broader graph structure:

$$P_{\text{struct}}(x_i \mid x_O) = \sum_{x_{H\setminus i}} P(x_i, x_{H\setminus i} \mid x_O).$$

Equivalently,

$$P_{\text{struct}}(x_i \mid x_O) \propto \sum_{x_{H\setminus i}} \left[\prod_{(u,v)\in E} \psi_{uv}(x_u, x_v) \prod_{u\in V} \phi_u(x_u) \right].$$

Under this hypothesis, distal evidence can propagate through latent nodes, so even when the local observed neighborhood of X_i is unchanged, its posterior may differ across graph conditions:

$$P^{(A)}_{\text{struct}}(x_i \mid x_O) \neq P^{(B)}_{\text{struct}}(x_i \mid x_O).$$

Minimal chain example. For the three-node chain

$$E - X_j - X_i,$$

the two hypotheses make different predictions. Under local independent inference,

$$P_{\text{ind}}(x_i \mid E) = P(x_i),$$

because X_i has no directly observed neighbor. Under structured inference,

$$P_{\text{struct}}(x_i \mid E) \propto \sum_{x_j} P(x_i \mid x_j) P(x_j \mid E),$$

so the distal evidence at E affects the posterior of X_i via the hidden intermediate node X_j.

1.2 Task design

1.3 Related Work

Prior work connects statistical physics, information theory, and cognition through constraint satisfaction models (Mézard & Mora, 2008). Belief Propagation (BP) and related message-passing methods have explained efficient inference in large-scale optimization and neural-inspired algorithms. In cognitive science, human reasoning has been modeled as probabilistic inference (Griffiths, Tenenbaum), but few studies have tested whether the *dynamics* of human reasoning—its temporal evolution—match known algorithmic convergence profiles. Neuroscientific frameworks like predictive coding and recurrent inference posit local error correction but have not mapped these precisely to algorithmic scheduling strategies. **The gap:** Empirical linking of behavioral sequences, algorithmic update dynamics, and neural temporal patterns remains untested.

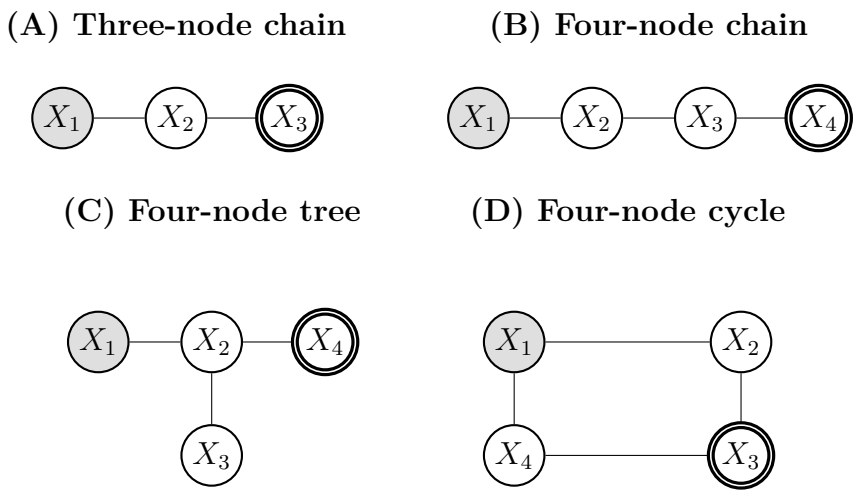

图 1: Graphical models used in the experiment. Gray nodes are observed evidence nodes (X_1; either hard or soft evidence), double-circle nodes are target nodes to be reported by participants, and single-circle nodes are latent unreported nodes.

1.4 Theoretical Framework

- **Core theory:** Humans solve structured reasoning problems through distributed, local message passing, akin to asynchronous BP on graphical models. Each attended variable update corresponds to a local message computation; scheduling (the order and timing of updates) determines efficiency and convergence, analogous to expertise.

- **Key predictions:**

  – Behavioral sequences reveal implicit scheduling strategies matching algorithmic scheduling rules (e.g., conflict-driven, uncertainty-driven).

  – Convergence rate and stability in human problem solving mirror BP convergence profiles.

  – Neural dynamics (oscillatory coupling, activity stabilization) correlate with algorithmic convergence curves.

  – Experts show faster convergence and reduced oscillatory instability—signatures of optimized scheduling.

- **Level of analysis:** Cognitive (reasoning steps and attention dynamics) → algorithmic (scheduling and convergence) → dynamical/circuit-level (recurrent neural message passing).

1.5 General Task Design

Paradigm Participants solve simplified CSPs (e.g., 4×4 Sudoku, 5-region map-coloring). Each variable (cell/region) is connected to constraints governing valid assignments. Participants interact via mouse clicks or gaze, allowing tracking of the **sequence and timing of variable updates**.

- **Independent variables:** Constraint density (analogous to clause density α); expertise level (novice vs. trained).
- **Dependent variables:** Sequence of attention/focus (scheduling traces), reaction times, corrections, solution time, accuracy.

Measurable Outcomes

- **Behavioral:** Sequences of variable selection, reaction times, confidence, constraint violation rate.
- **Neural:** EEG/MEG oscillations, fMRI activity coupling, or ECoG dynamics during reasoning.

1.6 Data Sources and Experimental Setup

- **Behavioral datasets:** Newly collected CSP solving data (lab-based or online), high temporal resolution.
- **Neural recordings:** EEG/MEG for timing, fMRI for network topology, possible ECoG or calcium imaging in animal models.
- **Limitations:** Requires alignment between behavioral updates and neural signals; BP model parameterization depends on known graph connectivity.

1.7 Computational Models and Analyses

Model Specification

- **Candidate models:**
    1. BP with different scheduling policies (random, sequential, conflict-driven, uncertainty-driven).
    2. Human-derived scheduling BP (using observed behavioral order).
    3. Null models: random search or heuristic solvers.

- **Parameters:** Scheduling rule weights, damping coefficients (belief stability), convergence rate constants (fit to behavioral and neural time courses).

Model Comparison

- Metrics: log-likelihood, BIC/AIC, cross-validation.
- Hierarchical comparison across participants to identify scheduling families.

Hypothesis Testing

- **Null:** Human sequences arise from random or heuristic search.
- **Test:** BP with individualized scheduling fits better to timing, sequence, and convergence trajectories.
- **Robustness:** Bootstrap and permutation tests.

Neural Data Analyses

- Encoding/decoding models linking neural patterns to BP message dynamics.
- Dimensionality reduction (PCA, GPFA) to identify latent convergence trajectories.
- Representational similarity between neural and algorithmic convergence curves (e.g., dynamic time warping).

1.8 Evaluation Plan

- **Behavioral:** Alignment between observed and modeled update order, correlation of convergence rates, recovery of scheduling parameters.
- **Neural:** Variance in neural activity explained by BP convergence, cross-correlation between neural stabilization and algorithmic energy minimization, similarity between neural and simulated belief trajectories.
- **Theory validation:** Consistent behavioral and neural evidence for BP-like convergence dynamics supports message-passing as a neural computation principle.

1.9 Next Steps and Open Questions

- **Planned experiments:** Scale complexity/constraint density to test phase-transition effects; longitudinal training to observe evolving scheduling strategies.
- **Risks:** Neural activity may reflect other cognitive processes (e.g., WM, planning); data may admit multiple model fits.
- **Mitigations:** Diverse task types, replication, and strong model-comparison criteria.
- **Generalization:** Theory extends to other reasoning domains (planning, language comprehension) where distributed constraint satisfaction and message passing are central.

Summary: This project operationalizes human reasoning as asynchronous Belief Propagation, tests its algorithmic traces in behavior, and maps its convergence dynamics to neural dynamics. By inferring each participant's implicit scheduling policy, we aim to reveal how cognitive expertise and brain networks jointly implement distributed probabilistic inference.

1.10 引言

约束满足问题（Constraint Satisfaction Problems, CSPs）构成高阶认知的计算基石。从规划日常行程到推演复杂社会层级，人类大脑须持续协调变量间的相互约束，以达成全局一致的认知状态。然而，支撑这一过程的算法架构至今仍是争论焦点。经典符号主义认知理论主张，人类通过串行启发式搜索求解此类问题——一个包含赋值、冲突检测与回溯的离散阶梯式过程（Newell & Simon, 1976）。源自概率计算与统计物理的新兴视角则提出，大脑可能运作如同分布式推断引擎，借助类似信念传播（Belief Propagation, BP）的并行消息传递算法，通过迭代一致化逼近边缘概率并收敛至解（Friston, 2010; Pegev & Pouget, 2023）。这两种观点代表了理解神经计算语法的根本性分歧：推理究竟是一系列严密的逻辑运算，还是动力系统向能量极小值的逐渐收敛过程？

地图填色任务为解决这一争议提供了理想的实验范式。与深受语义先验干扰的语言推理不同，地图填色分离了约束满足的纯结构动力学，使研究者得以在受控条件下考察计算机制本身。更为关键的是，CSP 在计算复杂性上表现出由约束-变量比率控制的剧烈相变现象。正是在这一临界区域——问题虽可解但计算代价高昂——不同算法的特征差异才最为显著。串行搜索模型预测反应时间将呈现由回溯深度驱动的重尾分布；分布式推断模型则预测，在系统未陷入局部极小值的前提下，收敛时间与网络规模呈对数关系（Zdeborová & Krzakala, 2016）。既往行为学研究多未能有效控制这一算法硬度参数，致使人类表现数据往往能被两类框架事后拟合，结论难以判定。

本研究提出一个统一的计算框架，旨在通过行为表型、跨任务迁移与神经动力学的三角互证来剖析这一机制。该框架的核心前提是：若大脑采用类 BP 机制，其”解”便不应仅是最终状态，而是对约束景观的一种鲁棒概率表征。据此，学习效应应当在具有拓扑同构性的地图间迁移——即局部消息传递结构保持不变——而非仅迁移抽象的启发式规则（如”优先填涂连接度最高的节点”）。这一区分至关重要：符号系统迁移的是产生式规则，而分布式系统迁移的是结构统计量。

对这两类模型的裁决还要求超越简单的激活映射，深入考察神经时间序列的几何特征。两种计算假说对神经状态轨迹提出了截然不同的预测。分布式推断过程意味着神经表征将呈现连续的、类梯度的演化，渐进逼近一致状态——这一过程可能映射为顶叶与前额叶皮层群体编码的逐渐锐化。相反，串行搜索蕴含着对应于决策节点与错误信号的离散突变式状态转换，极可能表现为与工作记忆更新相关的特定振荡爆发（如 theta-gamma 耦合）或重置信号。

通过将严谨的算法控制与高维神经解码相结合，本框架旨在超越”大脑即计算机”的简单隐喻，确定生物体在求解 NP 难问题时究竟依赖于对符号的精确句法操作，还是进化偏好了一种弛豫策略——即逻辑涌现于神经网络的动力学平衡过程之中。这一问题的解答不仅将厘清人类推理的架构边界，更将为设计具备灵活约束满足能力的神经形态系统提供理论基础。

2 Results

3 Results (Summary)

Present findings with minimal math and emphasize interpretation.

- Figures/tables showing behavioral fits.
- Neural alignment visualizations.
- Narrative link back to theory.

4 Methods (Technical Details)

Full mathematical and implementation details:

- Formal model equations.
- Derivations, likelihoods, priors.
- Estimation procedures (MLE, Bayesian).
- Simulation details.

5 方法（Methods）

5.1 概述

我们将实验任务形式化为图约束着色空间上的序列概率推断问题。每个 trial 向被试呈现一个部分展开的图 $G = (V, E)$，其中节点 V 表示离散随机变量，边 E 编码局部约束。被试在图结构逐步揭示的过程中，序列化地估计节点颜色的边缘后验分布。我们采用变量消元（variable elimination, VE）算法对这一过程建模。VE 是一种经典的精确推断算法，能够自然刻画序列信念更新的计算几何特征。该框架生成定量预测，将局部拓扑复杂度——通过诱导团大小和填充边数度量——与行为指标（包括反应时、不确定性和推断准确性）建立联系。

5.2 图着色的概率表示

5.2.1 任务形式化

每个 trial 由四元组 $T = (G, e, \lambda_e, o)$ 定义，其中 $G = (V, E)$ 为图结构，$e \in V$ 为证据节点，λ_e 为该节点的软证据，$o = (v_1, \ldots, v_T)$ 为查询序列。每个节点 $i \in V$ 对应一个离散随机变量 X_i，取值来自颜色集合 $C = \{R, G, B\}$。边施加硬约束，要求相邻节点颜色不同：

$$(i, j) \in E \Rightarrow X_i \neq X_j.$$

证据节点 e 在 trial 开始时以软概率分布 $\lambda_e = (\lambda_e(R), \lambda_e(G), \lambda_e(B))$ 的形式呈现，界面上显示为概率环。被试随后按预定顺序 o 依次报告对每个节点 v_t 的信念，其中 t 为查询步骤索引。每个响应 $y_t = (y_{t,R}, y_{t,G}, y_{t,B})$ 表示颜色上的概率分布，约束于 2-单纯形 Δ^2。

5.2.2 因子图表示

我们将着色约束满足问题表示为带硬约束和软证据的因子图。设 $x = (x_i)_{i \in V}$ 为完整的颜色赋值。对每条边 $(i, j) \in E$, 定义二元约束因子：

$$\psi_{ij}(x_i, x_j) = \mathbf{1}[x_i \neq x_j],$$

其中 $\mathbf{1}[\cdot]$ 为指示函数。节点 e 上的软证据编码为一元因子 $\phi_e(x_e) = \lambda_e(x_e)$。对所有非证据节点 $i \neq e$，设 $\phi_i(x_i) = 1$。联合分布因子化为：

$$p(x \mid G, \lambda_e) = \frac{1}{Z(G, \lambda_e)} \left[\prod_{i \in V} \phi_i(x_i) \right] \left[\prod_{(i,j) \in E} \psi_{ij}(x_i, x_j) \right],$$

其中 $Z(G, \lambda_e)$ 为配分函数。该形式化将着色任务统一于概率图模型框架，边因子编码拓扑约束，一元因子编码证据。

5.3 变量消元推断模型

5.3.1 序列推断机制

在第 t 步，被试需估计查询节点 v_t 的边缘后验分布。在静态贝叶斯解释下，规范目标为：

$$b_t(c) = P(X_{v_t} = c \mid G, \lambda_e), \quad c \in C.$$

然而，我们假设人类推断通过序列化机制运作，在节点被处理的过程中维护并更新内部表征。变量消元为这一假设提供了自然的形式化：认知系统并非每步从头计算边缘分布，而是增量式地边缘化已处理节点，将其影响压缩为约束剩余变量的中间因子。

5.3.2 活跃因子表示

我们定义一个 VE 代理，按任务指定的查询顺序 o 处理节点。在 trial 开始时，代理初始化活跃因子集：

$$\mathcal{F}^{(1)} = \{\phi_i(x_i) : i \in V\} \cup \{\psi_{ij}(x_i, x_j) : (i, j) \in E\}.$$

在第 t 步，设 $P_t = \{v_1, \ldots, v_{t-1}\}$ 为已处理节点集，$A_t = V \setminus P_t$ 为活跃变量集。因子集 $\mathcal{F}^{(t)}$ 表示代理消去 P_t 中所有节点后的内部状态。

5.3.3 边缘计算

为响应查询 v_t，代理在当前活跃因子下计算精确边缘分布：

$$b_t(x_{v_t}) \propto \sum_{x_{A_t \setminus \{v_t\}}} \prod_{f \in \mathcal{F}^{(t)}} f.$$

归一化后得到 $b_t = (b_t(R), b_t(G), b_t(B)) \in \Delta^2$，表示具有完整结构感知能力的规范贝叶斯后验。

5.3.4 通过消元更新因子

计算 b_t 后，代理通过边缘化 v_t 来消去该节点。设 $\mathcal{B}_t = \{f \in \mathcal{F}^{(t)} : v_t \in \mathrm{scope}(f)\}$ 为涉及 v_t 的因子集。消元操作产生新的中间因子：

$$m_t(x_{S_t}) = \sum_{x_{v_t}} \prod_{f \in \mathcal{B}_t} f,$$

其中作用域 $S_t = \left(\bigcup_{f\in\mathcal{B}_t} \mathrm{scope}(f)\right) \setminus \{v_t\}$ 包含 v_t 的所有原本不相邻的邻居。因子集随后更新为：

$$\mathcal{F}^{(t+1)} = \left(\mathcal{F}^{(t)} \setminus \mathcal{B}_t\right) \cup \{m_t\}.$$

该更新机制刻画了序列推断的计算几何：中间因子 m_t 耦合 S_t 中原本不相邻的节点，在内部表征中生成诱导边（fill-ins）。这些诱导依赖关系虽然在任务界面中不可见，但构成了后续推断步骤的结构负荷。

5.4 复杂度度量

VE 框架自然定义了量化每步推断计算代价的局部复杂度指标。设 $G^{(t)} = (A_t, E^{(t)})$ 为第 t 步的活跃图，$\mathcal{N}_t(v_t)$ 为 v_t 在该图中的邻居集。当 v_t 被消去时，其邻居将全连接形成团。我们定义两个关键指标：

诱导填充边数（$\mathbf{Fill}_t$）：

$$\mathrm{Fill}_t = |\{(i,j) : i,j \in \mathcal{N}_t(v_t),\, i \neq j,\, (i,j) \notin E^{(t)}\}|.$$

该指标量化消去 v_t 时必须表征的新条件依赖数量，刻画结构更新的代价。

诱导团大小（Ω_t）：

$$\Omega_t = |\mathcal{N}_t(v_t)| + 1.$$

该指标决定中间因子 m_t 的维度（状态空间大小为 $3^{\Omega_t - 1}$），直接对应工作记忆负荷和表征容量约束。

5.5 行为观测模型

为将代理的内部推断映射到可观测行为，我们引入两阶段转换。首先，响应温度参数 $\beta > 0$ 刻画概率报告中的系统性偏差：

$$\tilde{b}_t(c) = \frac{b_t(c)^\beta}{\sum_{c'\in C} b_t(c')^\beta}.$$

当 $\beta > 1$ 时，响应表现为概率锐化；当 $\beta < 1$ 时，响应向均匀分布退化。其次，为吸收运动和决策噪声，我们将观测响应建模为 Dirichlet 分布的抽样：

$$y_t \sim \mathrm{Dirichlet}(\kappa \tilde{b}_t),$$

其中浓度参数 $\kappa > 0$ 控制响应精度。较高的 κ 表示内部信念与外显响应的紧密耦合；较低的 κ 反映更强的行为噪声。

5.6 模型预测

若人类序列推断受类 VE 的图重构约束，而非无结构启发式，则行为指标应系统性地受局部拓扑几何（Ω_t 和 Fill_t）支配，而非全局图属性。该框架生成三个定量预测：

预测 1：计算代价与反应时。结构更新和记忆维持消耗时间资源。反应时应随拓扑复杂度增加：

$$\log RT_t = \alpha_0 + \alpha_1 \mathrm{Fill}_t + \alpha_2 \Omega_t + \epsilon_t.$$

预测 2：推断不确定性。高复杂度的拓扑重构稀释主观确定感，增加报告信念的香农熵：

$$H(y_t) = -\sum_c y_t(c) \log y_t(c) = \gamma_0 + \gamma_1 \mathrm{Fill}_t + \gamma_2 \Omega_t + \eta_t.$$

预测 3：计算坍塌与推断误差。当瞬时工作记忆负荷 Ω_t 超出容量限制时，系统无法维持高维诱导联合分布，退化为粗糙近似。观测响应 y_t 与规范后验 b_t 之间的 Kullback-Leibler 散度应随诱导团增大而急剧上升：

$$D_{\mathrm{KL}}(y_t \,\|\, b_t) = \sum_c y_t(c) \log \frac{y_t(c)}{b_t(c)} = \theta_0 + \theta_1 \Omega_t + \nu_t.$$

这些预测操作化了如下假设：人类在图上的概率推理从根本上受序列变量消元的计算几何约束。

5.1 信念传播类代理（BP-like Agents）

5.1.1 公共表征：约束图与马尔可夫随机场

两类代理共享相同的任务表征。地图填色问题定义在约束图

$$G_{\mathrm{csp}} = (V, E, C), \tag{1}$$

其中 V 为节点集合（对应待着色区域），E 为边集合（编码相邻互斥约束），C 为有限颜色集合。在该图上建立仅含成对势的马尔可夫随机场（MRF），其联合分布为

$$P(x) \propto \prod_{(i,j)\in E} \psi_{ij}(x_i, x_j), \tag{2}$$

其中 $x = (x_i)_{i\in V}$ 为全局着色赋值，成对势函数 ψ_{ij} 编码相邻节点的颜色兼容性：对于标准着色问题，$\psi_{ij}(x_i, x_j) > 0$（当 $x_i \neq x_j$ 时）而 $\psi_{ij}(x_i, x_j) = 0$（当 $x_i = x_j$ 时，硬约束），或取较大负对数惩罚值（软约束）。注意，本模型不包含显式的一元势（unary potential）；节点的先验偏好或已提交颜色信息均通过变量条件化（clamping）实现，而非引入额外节点势。

为便于后续算法描述，同时定义对数成对势：

$$J_{ij}(x_i, x_j) = \ln \psi_{ij}(x_i, x_j). \tag{3}$$

5.1.2 Max-Product BP 代理（无显式决策层）

模型定位 Max-product BP 代理作为规范性基线（normative baseline），与下一节的 BP-like 代理形成对照。该代理不包含逐步提交变量的决策层，也不显式建模外层时间步 t。它将地图着色视为上述 MRF 上的 MAP 推断问题，即寻找使全局联合对数概率最大化的赋值：

$$x^* = \arg\max_x \sum_{(i,j)\in E} J_{ij}(x_i, x_j). \tag{4}$$

代理在整张约束图上并行运行消息传递，其输出不是逐步填充的动作序列，而是随 BP 迭代演化的一条赋值轨迹及最终收敛解。

内部推断：Max-Sum 消息更新 代理的内部状态由一组沿有向边传递的对数消息构成：

$$\lambda^{(\tau)}_{i\to j}(c_j), \qquad i \in V,\ j \in N(i),\ c_j \in C, \tag{5}$$

其中 $\tau = 0, 1, \ldots$ 为迭代轮数，$N(i)$ 为节点 i 的邻居集合。初始化时，所有消息设为 0（对应概率域的均匀分布）。

在每轮迭代 $\tau \to \tau + 1$ 中，对每条有向边 $i \to j$ 及颜色 c_j，首先计算未阻尼的 max-sum 更新：

$$\hat{\lambda}^{(\tau+1)}_{i\to j}(c_j) = \max_{c_i\in C}\Big[J_{ij}(c_i, c_j) + \sum_{k\in N(i)\setminus\{j\}} \lambda^{(\tau)}_{k\to i}(c_i)\Big]. \tag{6}$$

为抑制有环图上的数值振荡，引入阻尼系数 $\alpha \in (0, 1]$，实际更新采用线性插值：

$$\lambda^{(\tau+1)}_{i\to j}(c_j) = (1-\alpha)\,\lambda^{(\tau)}_{i\to j}(c_j) + \alpha\,\hat{\lambda}^{(\tau+1)}_{i\to j}(c_j). \tag{7}$$

此外，为防止消息值无限漂移，每步对消息进行归一化处理（如减去该条消息在所有颜色上的均值或最大值）。迭代持续进行，直至满足以下任一终止条件：相邻两轮消息差的 L_1 范数小于阈值 ϵ（判定为收敛），或达到最大迭代次数 $T_{\max}$。

赋值轨迹与解的读出 在无显式决策层的设定下，max-product 代理的“当前状态”定义为各节点的最大边缘（max-marginal）估计。在第 τ 轮迭代，每个节点 i 的对数局部信念（log-belief）计算为

$$b^{(\tau)}_i(c) = \sum_{k\in N(i)} \lambda^{(\tau)}_{k\to i}(c), \qquad c \in C. \tag{8}$$

$b^{(\tau)}_i(c)$ 近似了 $\ln P(x_i = c,\, x^*_{V\setminus i})$，即假设节点 i 取颜色 c 时，其余变量取最优配置下的全局对数得分。

代理在第 τ 步的赋值：

$$x^{(\tau)}_i = \arg\max_{c\in C}\ b^{(\tau)}_i(c), \qquad \forall\, i \in V. \tag{9}$$

由此得到该代理的赋值轨迹：

$$\mathcal{T} = \{x^{(0)}, x^{(1)}, \ldots, x^{(T_{\max})}\}. \tag{10}$$

随着消息传递的推进，赋值 $x^{(\tau)}$ 逐步演化。当消息收敛或赋值在连续 K_{stab} 轮迭代中保持不变时，最终的 $x^{(\tau)}$ 即被视为该代理给出的近似 MAP 解。

5.1.3 Sum-Product BP + 决策层

模型架构 与 max-product 代理的全局并行一致化策略不同，BP-like 代理被构造为一个推断–决策两层过程模型，在每个外层时间步 t 交替执行两个阶段：

- **推断层**：在当前已提交部分赋值的条件下，运行 sum-product BP，输出每个未提交节点的近似边缘分布；
- **决策层**：基于推断层输出的边缘分布，通过熵排序与温度调节的 softmax 机制，生成“下一步在哪个节点填什么颜色”的动作。

该模型的核心区别在于：它显式建模逐步填色的时间过程，每步提交一个变量赋值并将其条件化到后续推断中，从而生成一条与人类操作序列直接可比的动作轨迹。

状态表示 记第 t 个外层时间步的已提交节点集合为 $A_t \subseteq V$，对应的部分赋值为映射

$$y_t\colon A_t \to C, \qquad y_t(i) = \text{节点 } i \text{ 已提交的颜色}. \tag{11}$$

未提交节点集合记为

$$F_t = V \setminus A_t. \tag{12}$$

初始时 $A_0 = \emptyset$。

推断层：条件 MRF 上的 Sum-Product BP 推断层的任务是：给定当前部分赋值 (A_t, y_t)，计算剩余未提交节点上的近似边缘分布。

条件化的马尔可夫随机场。在给定部分赋值 (A_t, y_t) 的条件下，原始 MRF 的联合分布化为条件分布

$$P_t(x_{F_t} \mid x_{A_t} = y_t) \propto \prod_{(i,j)\in E} \psi_{ij}(x_i, x_j), \tag{13}$$

其中 $i \in A_t$ 的变量 x_i 已被固定为 $y_t(i)$，而 $i \in F_t$ 的变量仍在颜色集合 C 上自由取值。

消息传递。为图上每条有向边 $i \to j$ 维护一条消息函数

$$m_{i\to j}^{(t,\tau)}(c_j), \qquad i \in V,\ j \in N(i),\ c_j \in C,\ \tau = 0, \ldots, T_{\text{bp}}, \tag{14}$$

其中 τ 为本时间步内部 BP 的迭代索引，T_{bp} 为每一外层时间步的内部 BP 迭代轮数。对每条有向边 $i \to j$，内部第 $\tau + 1$ 轮迭代的未阻尼消息 $\hat{m}_{i\to j}^{(t,\tau+1)}$ 根据节点 i 的状态分两种情形更新：

(1) 未提交节点（$i \in F_t$）：x_i 为需要求和的随机变量，

$$\hat{m}_{i\to j}^{(t,\tau+1)}(c_j) \propto \sum_{c_i \in C} \psi_{ij}(c_i, c_j) \prod_{k \in N(i)\setminus\{j\}} m_{k\to i}^{(t,\tau)}(c_i), \qquad c_j \in C. \tag{15}$$

(2) 已提交节点（$i \in A_t$）：x_i 被固定为 $y_t(i)$，不再对 c_i 求和，

$$\hat{m}_{i\to j}^{(t,\tau+1)}(c_j) \propto \psi_{ij}\big(y_t(i), c_j\big), \qquad c_j \in C. \tag{16}$$

已提交节点仅向邻居传播一个由自身固定颜色与边势决定的静态消息，不受其他传入消息的影响。

与 max-product 代理类似，引入阻尼系数 $\alpha \in (0, 1]$ 以提高数值稳定性：

$$m_{i\to j}^{(t,\tau+1)}(c_j) = (1-\alpha)\, m_{i\to j}^{(t,\tau)}(c_j) + \alpha\, \hat{m}_{i\to j}^{(t,\tau+1)}(c_j), \qquad c_j \in C. \tag{17}$$

在本外层时间步内完成 T_{bp} 轮迭代后，得到最终消息集合

$$\big\{m_{i\to j}^{(t,T_{\mathrm{bp}})}\big\}. \tag{18}$$

信念计算。由最终消息为每个未提交节点 $i \in F_t$ 计算近似边缘分布：

$$b_i^{(t)}(c) \propto \prod_{k \in N(i)} m_{k\to i}^{(t,T_{\mathrm{bp}})}(c), \qquad c \in C, \tag{19}$$

再对 c 归一化使 $\sum_c b_i^{(t)}(c) = 1$。对于已提交节点 $i \in A_t$，其边缘分布为退化分布：

$$b_i^{(t)}(c) = \begin{cases} 1, & c = y_t(i), \\ 0, & c \neq y_t(i). \end{cases} \tag{20}$$

推断层输出。在外层时间步 t 结束时，推断层输出定义在整张图上的信念场

$$b^{(t)} = \big\{b_i^{(t)}(c) : i \in V,\ c \in C\big\}, \tag{21}$$

表示在当前已提交条件下各节点对各颜色的局部支持程度，作为决策层的输入。

决策层：基于熵的节点–颜色选择 决策层的任务是：给定推断层输出的信念场 $b^{(t)}$，生成本时间步的动作

$$a_t = (i_t, c_t). \tag{22}$$

决策过程分为节点选择与颜色选择两个阶段。

节点选择：熵驱动的 softmax。对每个未提交节点 $i \in F_t$，计算其当前边缘分布的熵：

$$H_i^{(t)} = -\sum_{c \in C} b_i^{(t)}(c)\, \log b_i^{(t)}(c). \tag{23}$$

熵 $H_i^{(t)}$ 越小，表明该节点的颜色分布越尖锐，代理对其颜色选择越有把握；熵越大，则多种颜色可能性相当，内部尚未形成明确偏好。为偏好优先填色那些内部已较为确定的节点，将节点优先级定义为负熵：

$$u_i^{(t)} = -H_i^{(t)}, \tag{24}$$

并利用逆温度参数 $\beta_{\text{node}} \geq 0$ 构造节点选择的 softmax 分布：

$$\pi_{\text{node}}\big(i \mid b^{(t)}\big) = \frac{\exp\big(\beta_{\text{node}}\, u_i^{(t)}\big)}{\sum_{k\in F_t} \exp\big(\beta_{\text{node}}\, u_k^{(t)}\big)}, \qquad i \in F_t. \tag{25}$$

当 $\beta_{\text{node}} \to 0$ 时，π_{node} 趋近于未提交节点上的均匀分布；当 β_{node} 较大时，节点选择高度集中于熵最小的少数节点，近似“总是先填最确定节点”的贪心策略。代理从 $\pi_{\text{node}}(\cdot \mid b^{(t)})$ 中抽样得到操作节点 i_t。

颜色选择：边缘驱动的 softmax。在节点 i_t 被选定后，根据其边缘分布 $b_{i_t}^{(t)}(c)$ 生成填色动作。基础颜色选择分布定义为对边缘分布的幂变换：

$$\tilde{\pi}_{\text{color}}\big(c \mid b_{i_t}^{(t)}\big) = \frac{\big(b_{i_t}^{(t)}(c)\big)^{1/\tau_{\text{act}}}}{\sum_{c'\in C}\big(b_{i_t}^{(t)}(c')\big)^{1/\tau_{\text{act}}}}, \qquad c \in C, \tag{26}$$

其中 $\tau_{\text{act}} > 0$ 为动作层温度参数。当 $\tau_{\text{act}} \to 0$ 时，该分布趋近于对 $\arg\max_c b_{i_t}^{(t)}(c)$ 的确定性选择；当 τ_{act} 较大时，更接近按边缘分布进行概率匹配。

为捕捉偶发失误或注意力波动，引入失误概率（lapse probability）$p_{\text{lapse}} \in [0, 1)$：在该概率下，代理不参考 $b_{i_t}^{(t)}$，而是在颜色集合 C 上均匀随机选择。综合两部分，实际颜色选择概率为

$$\pi_{\text{color}}\big(c \mid b_{i_t}^{(t)}\big) = (1 - p_{\text{lapse}})\, \tilde{\pi}_{\text{color}}\big(c \mid b_{i_t}^{(t)}\big) + p_{\text{lapse}} \frac{1}{|C|}, \qquad c \in C. \tag{27}$$

决策层输出。本时间步的完整动作概率由节点选择与颜色选择的联合概率给出：

$$P\big(a_t = (i_t, c_t) \mid \text{历史}, \Theta\big) = \pi_{\text{node}}\big(i_t \mid b^{(t)}\big) \cdot \pi_{\text{color}}\big(c_t \mid b_{i_t}^{(t)}\big), \tag{28}$$

其中参数集 Θ 汇总了推断层参数 (α, T_{bp}) 与决策层参数 $(\beta_{\text{node}}, \tau_{\text{act}}, p_{\text{lapse}})$。

状态更新与迭代循环 一旦动作 $a_t = (i_t, c_t)$ 被采样并执行，部分赋值从 (A_t, y_t) 更新为

$$A_{t+1} = A_t \cup \{i_t\}, \qquad y_{t+1}(i) = \begin{cases} y_t(i), & i \in A_t, \\ c_t, & i = i_t. \end{cases} \tag{29}$$

在概率图模型层面，该步骤等价于对变量 x_{i_t} 做条件化：令 $x_{i_t} = c_t$，并在后续 sum-product BP 更新中将 i_t 始终视为观测变量。形式上，这通过在消息更新时对 $i \in A_{t+1}$ 使用

$$\hat{m}_{i\to j}(c_j) \propto \psi_{ij}\big(y_{t+1}(i), c_j\big) \tag{30}$$

来实现，无需显式引入新的节点势。

随后进入下一外层时间步 $t+1$：推断层在新的条件 MRF $P_{t+1}(x_{F_{t+1}} \mid x_{A_{t+1}} = y_{t+1})$ 上运行 T_{bp} 轮 sum-product BP，输出更新后的信念场 $b^{(t+1)}$；决策层再据此生成下一步动作。以此循环，直至所有节点均已提交（得到完整着色方案）或达到预设的外层步数上限。

5.2 经典搜索代理（CSP 求解器）

我们构建一个基于约束满足问题（Constraint Satisfaction Problem, CSP）框架的经典搜索代理。该代理采用深度优先搜索（DFS）与回溯策略，并辅以变量排序、值排序与前向检查等启发式技术。

与前述 BP 类代理不同，CSP 求解器不维护概率分布或消息场，而是通过系统性枚举与剪枝来寻找满足所有约束的完整赋值。

5.2.1 CSP 形式化

在约束图 $G_{\mathrm{csp}} = (V, E, C)$ 上，地图着色问题被形式化为如下 CSP：

- **变量集合**：$X = \{X_i : i \in V\}$，每个变量 X_i 对应图中的一个节点。
- **值域**：每个变量 X_i 的初始值域为 $D_i = C$，即所有可用颜色的集合。
- **约束集合**：对每条边 $(i, j) \in E$，存在二元不等约束 $X_i \neq X_j$。

赋值记为映射 $\sigma\colon A \to C$，其中 $A \subseteq V$ 为已赋值节点集合。若 $\sigma(i) = c$，表示变量 X_i 被赋予颜色 c。

赋值 σ 称为一致的（consistent），当且仅当对每条边 $(i, j) \in E$，若 $i, j \in A$，则 $\sigma(i) \neq \sigma(j)$。解定义为一个定义在全体 V 上且一致的完整赋值，即 $A = V$ 且满足所有约束。

5.2.2 变量排序策略

设当前赋值为 σ，已赋值节点集合为 $A = \mathrm{dom}(\sigma)$，未赋值节点集合为 $U = V \setminus A$。若启用前向检查，记 D_i 为节点 i 在约束传播后的当前剩余值域。

下一待赋值节点由以下策略之一选取：

1. **静态顺序（Static）**：按预先给定的节点编号顺序，选取 U 中索引最小的节点。
2. **最小剩余值（MRV）**：选取剩余合法颜色数最少的节点：

$$i^* \in \arg\min_{i \in U} |D_i|. \tag{31}$$

若未启用前向检查，则 $D_i \equiv C$，该策略退化为静态顺序。

3. **度启发式（Degree）**：选取与未赋值节点相邻数量最多的节点：

$$i^* \in \arg\max_{i \in U} \Big| \{ j \in N(i) : j \in U \} \Big|, \tag{32}$$

其中 $N(i)$ 为节点 i 的邻居集合。

4. **MRV + 度（MRV + Degree）**：先按 MRV 策略得到候选集

$$U_{\text{mrv}} = \arg\min_{i \in U} |D_i|; \tag{33}$$

若 $|U_{\text{mrv}}| = 1$ 则直接选取该节点，否则在 U_{mrv} 上按度启发式进一步筛选。

5. **随机（Random）**：从 U 中均匀随机选取。

当存在多个并列候选时，可配置随机打平（random tie-breaking）。

5.2.3 值排序策略

对已选定的节点 i，其当前可用颜色集合记为 D_i^{avail}（若启用前向检查则为当前剩余值域 D_i，否则为完整颜色集合 C）。为节点 i 尝试颜色的顺序由以下策略之一决定：

1. **静态顺序（Static）**：按预先给定的颜色编号顺序。

2. **随机（Random）**：将 D_i^{avail} 均匀随机打乱。

3. **最少约束值（LCV）**：对每种颜色 $c \in D_i^{\text{avail}}$，计算若将节点 i 赋为 c，会从多少未赋值邻居的值域中排除该颜色：

$$\text{count}(c) = \sum_{j \in N(i),\, j \in U} \mathbb{1}[c \in D_j], \tag{34}$$

按 $\text{count}(c)$ 升序排列，优先尝试对邻居限制更少的颜色。

5.2.4 一致性检查与前向检查

一致性检查：对当前赋值 σ 与候选赋值 (i, c)，若存在邻居 $j \in N(i)$ 满足 $j \in A$ 且 $\sigma(j) = c$，则 (i, c) 与 σ 不一致，该赋值被拒绝。

前向检查（Forward Checking）：在执行赋值 $X_i = c$ 后，更新所有未赋值邻居的值域：对每个 $j \in N(i) \cap U$，令

$$D'_j = D_j \setminus \{c\}. \tag{35}$$

若存在某 j 满足 $D'_j = \emptyset$，则前向检查失败，当前赋值分支被剪枝，搜索回溯。

5.2.5 搜索过程与输出

CSP 求解器通过深度优先搜索遍历赋值空间。在每一步，代理根据变量排序策略选取下一个待赋值节点 i^*，再根据值排序策略依次尝试 $D_{i^*}^{\text{avail}}$ 中的颜色。对每个候选颜色 c：

- 执行一致性检查；若不一致则跳过；
- 若启用前向检查，执行值域传播；若失败则跳过；
- 若通过，则将 (i^*, c) 加入赋值 σ，递归搜索；
- 若递归返回失败，则回溯，撤销赋值并尝试下一颜色。

当 $A = V$ 时，搜索成功，输出完整赋值 σ 作为解。若所有分支均被剪枝，则报告无解。

5.3 局部搜索方法（Min-Conflicts）

本方法在**完整赋值**空间上进行迭代修复，不进行树搜索也不使用概率推断：每次选取一个当前存在冲突的变量，将其颜色改为使该变量上冲突数最小的颜色（Min-Conflicts 启发式），直到无冲突或达到步数上限。

5.3.1 状态与目标

状态表示为全局完整赋值 $x = (x_i)_{i \in V}$，其中每个节点 $x_i \in C$。定义冲突边集与全局冲突数：

$$E_{\text{viol}}(x) = \big\{(i, j) \in E : x_i = x_j\big\}, \tag{36}$$

$$E(x) = \big|E_{\text{viol}}(x)\big|. \tag{37}$$

目标为最小化 $E(x)$，合法解满足 $E(x) = 0$。

5.3.2 初始赋值

可选两种初始化方式：

1. **随机**：对每个节点 $i \in V$ 独立、均匀随机地从颜色集 C 中抽取初始颜色 x_i。
2. **贪心**：按某一给定顺序（如随机打乱后的节点序）依次为节点赋色；对当前节点 i，在 C 中选取使「与已赋值邻居同色次数」最少的颜色，若有多解则随机打平；若无合法颜色则随机取一色。

5.3.3 邻域与 Min-Conflicts 步

冲突节点集：在当前赋值 x 下，至少与一名邻居同色的节点集合定义为

$$V_{\text{conf}}(x) = \big\{i \in V : \exists j \in N(i),\ x_i = x_j\big\}. \tag{38}$$

单步更新：从 $V_{\text{conf}}(x)$ 中任选一节点 i^*（实现中可均匀随机选取）。对 i^* 的 **Min-Conflicts** 更新规则为：在颜色集 C 中选择使 i^* 上局部冲突数最小的颜色，即

$$c^* \in \arg\min_{c \in C} \big|\big\{j \in N(i^*) : x_j = c\big\}\big|, \tag{39}$$

其中 x_j（$j \neq i^*$）为当前赋值，节点 i^* 此时被视为尝试赋值为 c。若有多个颜色 c 达到最小冲突数，可随机选取其一（random tie-breaking）。随后执行状态更新 $x_{i^*} \leftarrow c^*$，得到新状态，并重复此过程直至 $E(x) = 0$ 或达到最大步数上限。

该算法不完备：可能陷入局部最优（存在冲突但每个冲突节点的任意改色都会使冲突数不变或增加）；但在许多实例上收敛较快，适合作为快速启发式策略。

5.4 模拟退火方法（Simulated Annealing）

本方法同样在完整赋值空间上搜索，以全局冲突数为目标函数（能量函数），通过引入**温度**控制的概率接受准则来允许「变差」的状态转移，从而帮助代理逃离局部最优。

5.4.1 状态、目标与邻域

状态表示为全局完整赋值 $x = (x_i)_{i \in V}$，其中 $x_i \in C$。目标函数（能量）取为全图的冲突边数：

$$E(x) = \big|\big\{(i,j) \in E : x_i = x_j\big\}\big|. \tag{40}$$

邻域定义：任选一节点 $i \in V$ 与一颜色 $c \in C$，将 x_i 的取值更改为 c，得到邻域提议状态 x'（仅节点 i 的取值发生变化）。

5.4.2 接受准则与降温

设当前状态为 x，能量为 $E(x)$；提议状态为 x'，能量为 $E(x')$。记能量变化量为 $\Delta E = E(x') - E(x)$。提议状态 x' 的转移接受概率定义为：

$$P(\text{接受}x') = \begin{cases} 1, & \Delta E \leq 0, \\ \exp\big(-\frac{\Delta E}{T}\big), & \Delta E > 0, \end{cases} \tag{41}$$

其中 $T > 0$ 为当前温度参数。具体而言：

- 若 $\Delta E \leq 0$，代理必然接受 x'（冲突数减少或不变）。
- 若 $\Delta E > 0$，代理以概率 $\exp(-\Delta E/T)$ 接受 x'，否则拒绝转移并保持原状态 x。

温度 T 随迭代步数动态更新：每步按几何降温机制更新 $T \leftarrow \alpha T$，其中 $\alpha \in (0,1)$ 为降温系数。实现中可设置温度下限 $T_{\min}$，当 $T < T_{\min}$ 时算法终止或转为仅接受不退化的贪心移动。

理论上在适当的降温进度下（如对数降温），模拟退火可渐近收敛到全局最优；实践中常用上述几何降温，并通过初始温度 T_0、降温系数 α、最大步数等超参数控制计算开销。该算法虽不完备，但能在有限步内以较高概率找到合法解或低冲突赋值。

5.5 小结

经典搜索方法将问题形式化为 CSP，通过变量/值排序与前向检查在 DFS 回溯框架下求精确解，具有完备性；贝叶斯方法将问题建模为马尔可夫网络，用 BP 得到信念后通过消减逐变量固定，得到单一赋值，并可用期望冲突与 MAP 冲突监控求解过程。局部搜索（Min-Conflicts）在完整赋值上迭代修复，每步对一冲突节点做最小冲突改色，实现简单、收敛快但不完备；模拟退火同样在完整赋值上搜索，以冲突数为能量、以温度控制接受变差移动，便于逃离局部最优。四种方法在实现上可共用同一图与颜色集，便于对比与可视化。

参考文献