# Pre-Analysis 2

$\rho$-agent simulation study

2026 年 3 月 27 日

## 目录


**1 执行目标** **1**

**2 图枚举、目标放置与模型实现** **1**

2.1 图枚举 . . . . . 1

2.2 $\rho$-agent . . . . . 2

**3 证据分配策略比较** **2**

**4 完整 5 节点模拟结果** **3**

**5 Equal-local, distinct-remote 图对** **7**

**6 结论** **7**


## 1 执行目标

本分析对应 ‘TODO-2.md‘，只回答两个问题：

1. 在最小图集上，$M_\rho$ 是否能产生可分离的结构化预测？
2. 从 $\rho = 0$ 到 $\rho = 1$ 的连续谱，是否在完整 5 节点刺激集上仍然保持可计算、可解释？

按照 AGENTS 的硬约束，本分析全部使用 $\beta_{\text{edge}} = 4$，并对每张图做精确穷举（$3^5 = 243$ 个颜色赋值），绝不使用 BP 或其他近似来代替 $M_\rho$。

## 2 图枚举、目标放置与模型实现

### 2.1 图枚举

我们穷举了所有 5 节点无向图，并保留其中**连通且 3-colorable** 的非同构图。结果共得到

张图。每张图都将目标节点 $X$ 放在图中心（graph center）；若中心不唯一，则在所有中心诱导的 rooted-canonical 形式中选取字典序最小者。所有非目标节点均为带不确定性的 soft evidence 节点。

### 2.2 $\rho$-agent

5 个代理固定为

$$A_0 : \rho = 0.00, \quad A_1 : \rho = 0.25, \quad A_2 : \rho = 0.50, \quad A_3 : \rho = 0.75, \quad A_4 : \rho = 1.00.$$

每个代理都对同一修改后图模型做**精确**求和：

$$\psi_{uv}^{(\rho)}(x_u, x_v) = \exp\Big[-\beta_{\text{edge}}\, \rho^{s(u,v)}\, \mathbf{1}(x_u = x_v)\Big], \qquad s(u,v) = \min(d(X,u), d(X,v)).$$

因此 $A_0$ 是局部独立极限，$A_4$ 是全局精确极限，中间 3 个代理给出连续的 bounded spectrum。

## 3 证据分配策略比较

TODO-2 的开放设计变量是 non-target evidence 如何赋值。我们比较了三种候选：

1. **uniform**：4 个 evidence 节点都偏向同一颜色；
2. **fixed conflicting**：使用一个对全部图固定的冲突模板；
3. **adaptive conflicting**：对每张 rooted graph，在所有非均匀模板里选择一个模板，使

$$\sum_{\rho_i < \rho_j} D_{\text{KL}}(\tilde{b}_{\rho_i} \,\|\, \tilde{b}_{\rho_j})$$

最大，同时要求 $p_R$ 与 $H(\tilde{b}_\rho)$ 在 5 个 $\rho$ 水平上单调（容差 $5 \times 10^{-4}$）。

fixed conflicting 的最佳全局模板是

$$(R, B, R, G),$$

其中 evidence 节点按“距目标的 shell 距离递增；同 shell 内按 rooted-canonical 顺序”排序。

| 策略 | 单调图数 | 高证据可分离图数 | $\sum_{i<j} D_{\text{KL}}$ | 相对 uniform 倍数 |
|---|---|---|---|---|
| uniform | 15 / 17 | 10 / 17 | 6.183 | 1.000 |
| fixed conflicting | 17 / 17 | 15 / 17 | 9.134 | 1.477 |
| adaptive conflicting | 17 / 17 | 16 / 17 | 23.125 | 3.740 |

表 1: 证据分配策略比较。adaptive conflicting 在 TODO 指定的总 pairwise separability 指标上明显最优，因此被选为后续完整模拟的正式设计。

另外，adaptive conflicting 的相邻 KL 总和为 2.224，而 uniform 仅为 0.680，增益为 3.270 倍。说明区分相邻 $\rho$ 水平时，冲突设计同样显著更强。

# 4 完整 5 节点模拟结果

最终模拟全部采用 adaptive conflicting。主要结果如下：

1. 17 张图里有 16 张在 high evidence 下满足

$$D_{\mathrm{KL}}(\tilde{b}_0 \,\|\, \tilde{b}_1) > 0.01,$$

   超过 TODO 要求的 10 张图。

2. 所有 17 张图在 5 个 $\rho$ 水平上的 $p_R$ 与 $H(\tilde{b}_\rho)$ 都满足单调性（容差 $5 \times 10^{-4}$）。

3. 最大的“非严格单调”偏差只出现在 low evidence 下，$p_R$ 的最大回摆为 $2.13 \times 10^{-4}$，熵的最大回摆为 $4.10 \times 10^{-5}$；都远小于主效应量级，因此可视为近乎平坦条件下的数值微扰。

4. 一张 4-star 图在所有边都位于 shell 0，因此 $\rho$ 不起作用，形成唯一的“collapsed”图；其余 16 张图都给出可见分离。

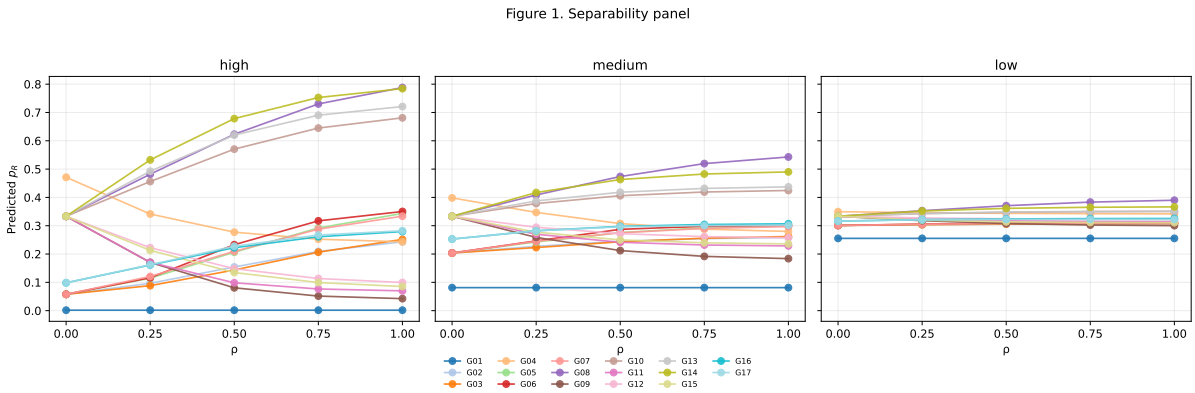


图 1: Figure 1. 对每个 evidence level，画出 17 张图的 $p_R$–$\rho$ 曲线。除 4-star 退化图外，其余图的 5 个 $\rho$ 水平均可分离。

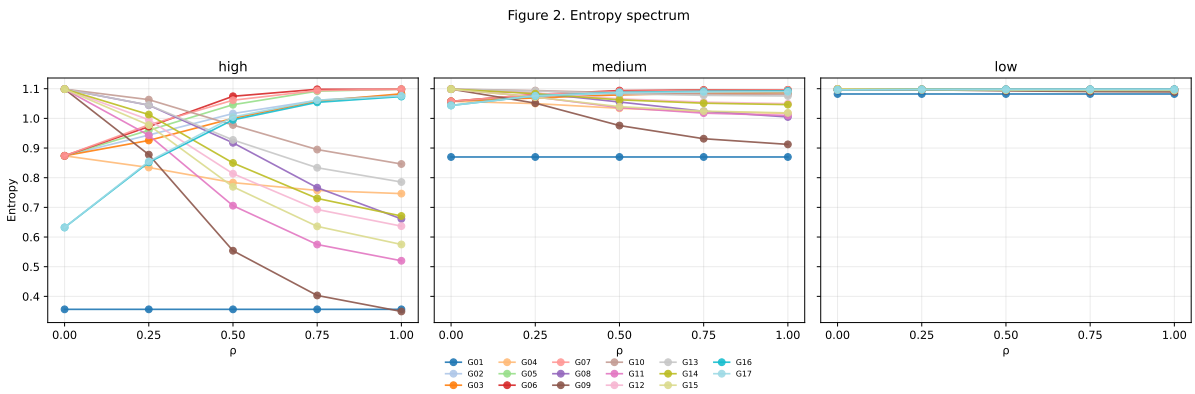


图 2: Figure 2. 对每个 evidence level，画出 17 张图的响应熵谱。adaptive conflicting 设计下，熵随 $\rho$ 呈稳定的单调变化。

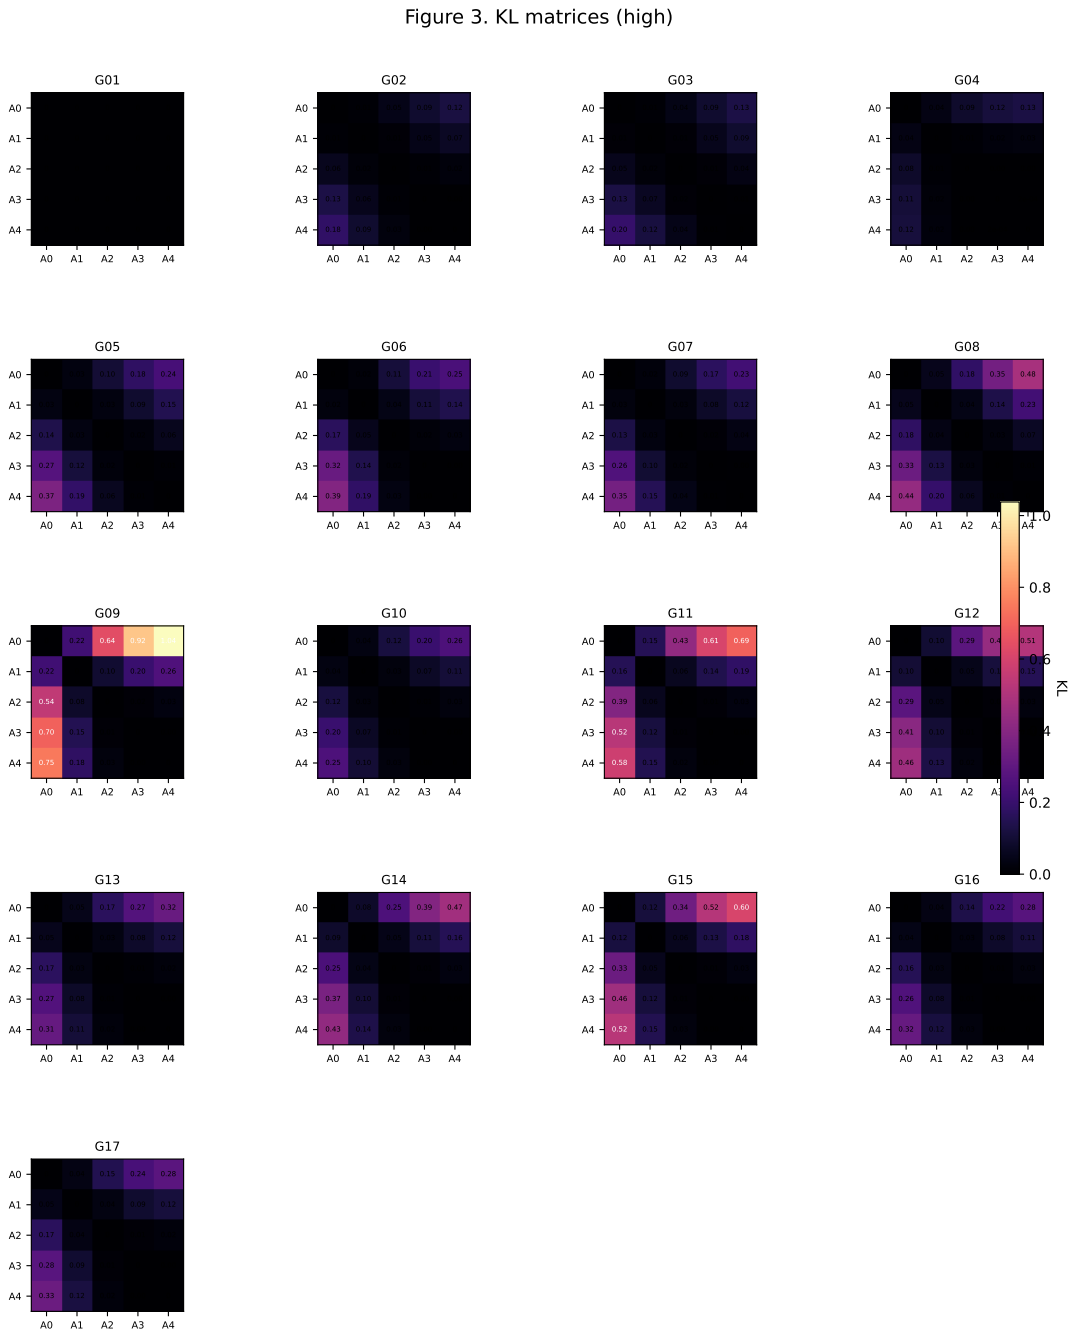


图 3: Figure 3a. high evidence 下每张图的 5×5 directed KL matrix。颜色越深，两个 $\rho$ 代理越容易区分。

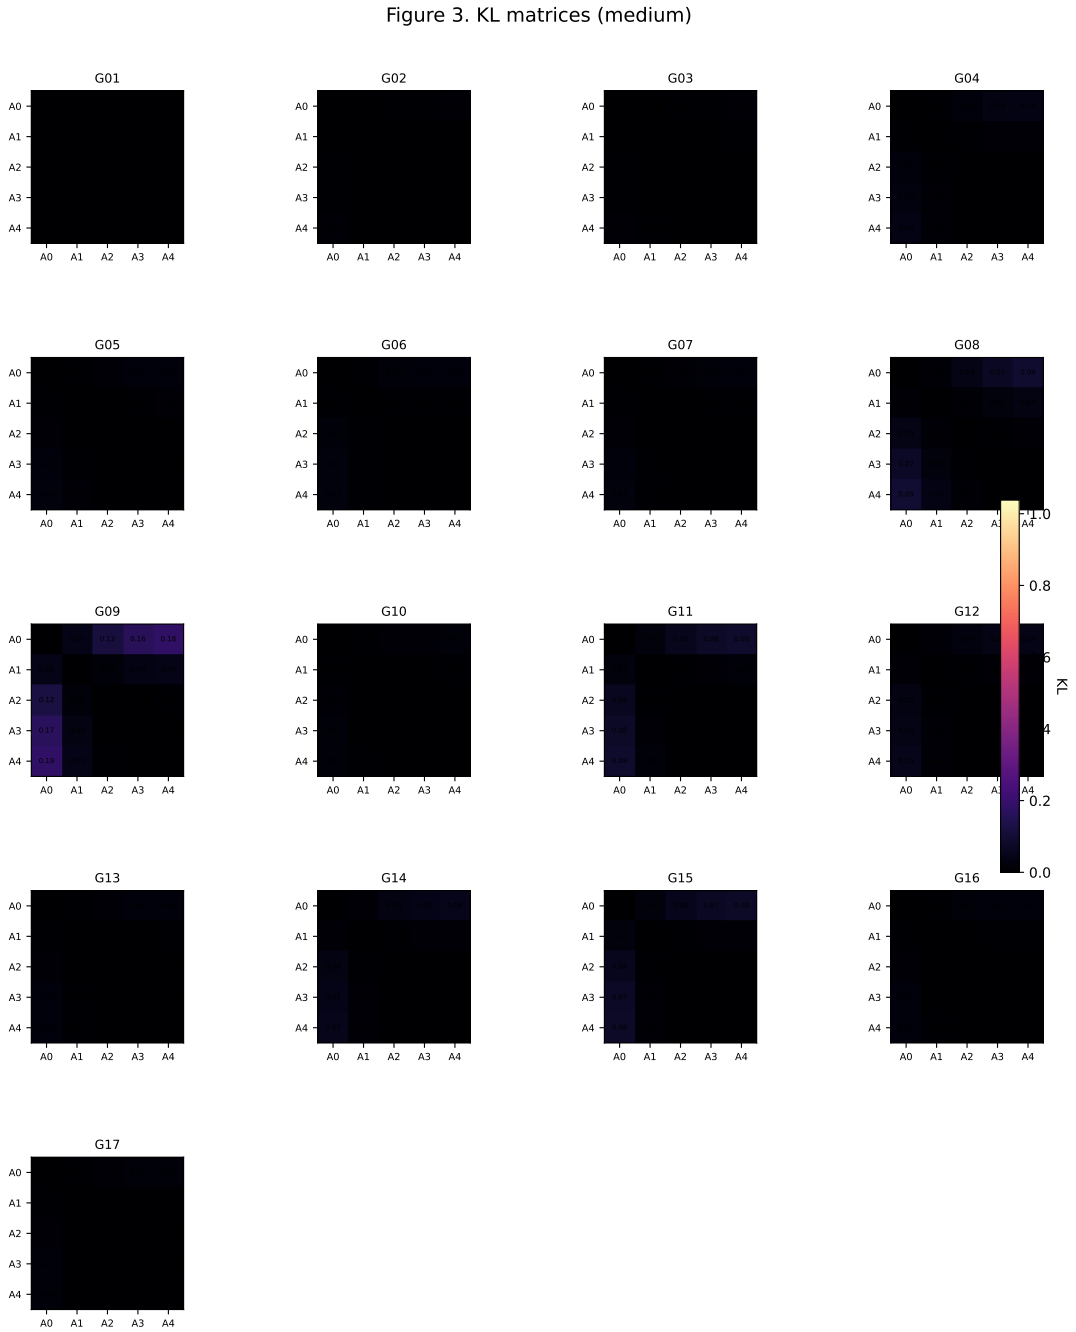


图 4: Figure 3b. medium evidence 下的 directed KL matrix。

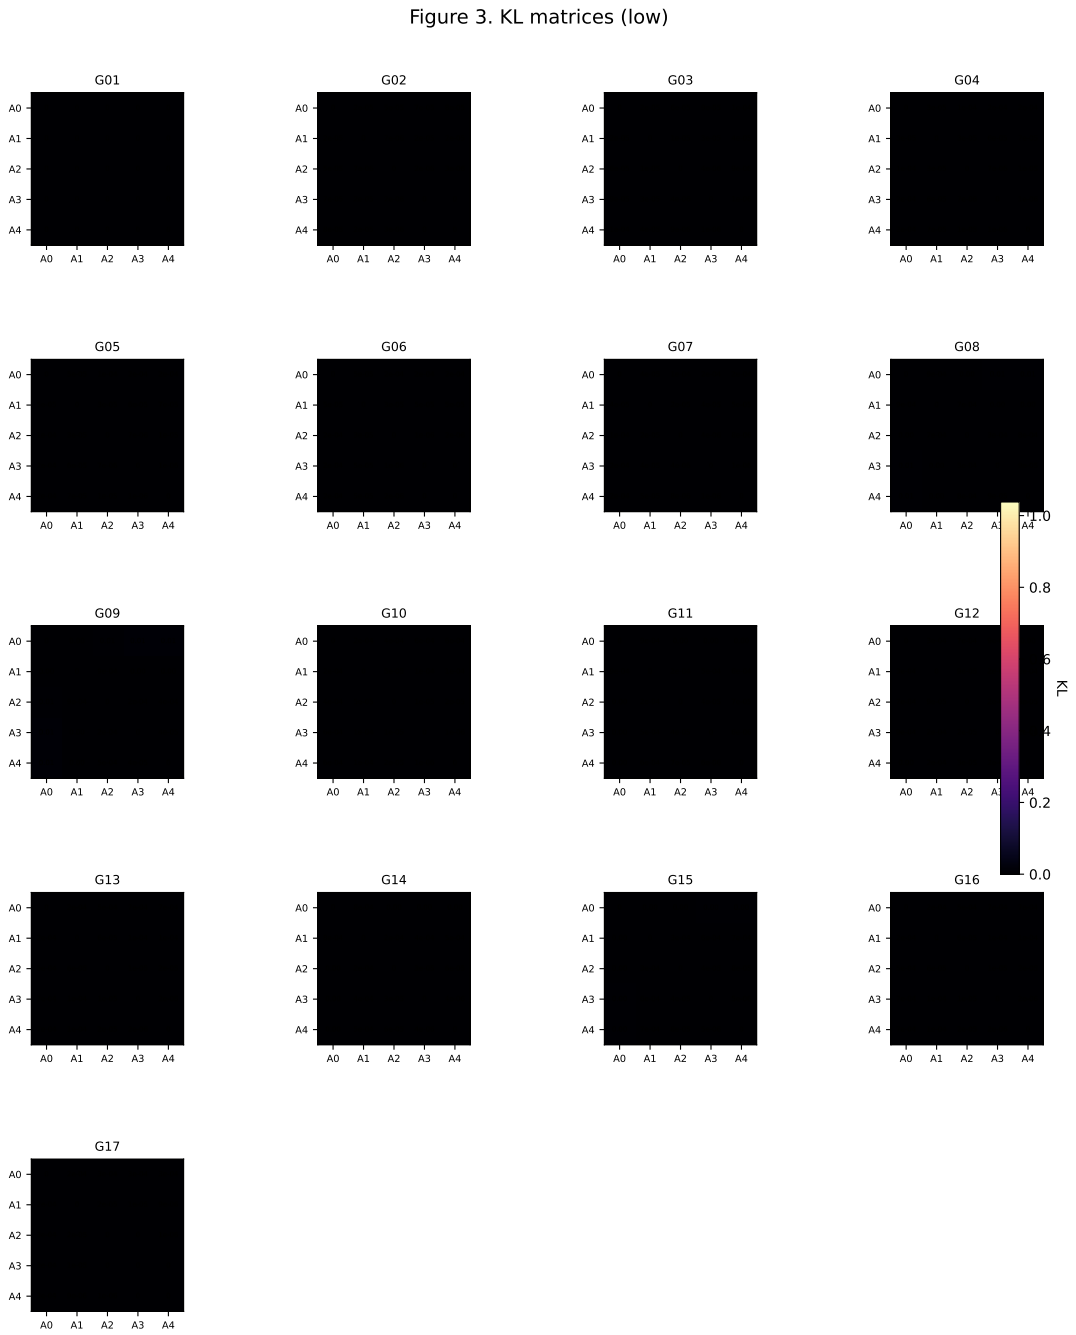


图 5: Figure 3c. low evidence 下的 directed KL matrix。整体分离度下降，但多数图仍保持有序谱。

# 5 Equal-local, distinct-remote 图对

在最终刺激集中，我们找到了一个非常强的 equal-local 图对：‘G08‘ 与 ‘G09‘。这两张图都让目标节点 $X$ 连接到 3 个 shell-0 evidence 节点，且这 3 个局部节点的颜色偏好完全相同（分别为 $R, B, G$），因此 $A_0$ 在两图上的预测完全一致：

$$\tilde{b}_0^A = \tilde{b}_0^B = (1/3, 1/3, 1/3).$$

但加入 remote structure 后，$A_4$ 在 high evidence 下分裂为

$$\tilde{b}_1^A = (0.788, 0.122, 0.090), \qquad \tilde{b}_1^B = (0.042, 0.915, 0.042),$$

对应的 symmetric KL 达到 3.814，说明远端结构足以在 “局部完全相同” 的条件下翻转全局预测。

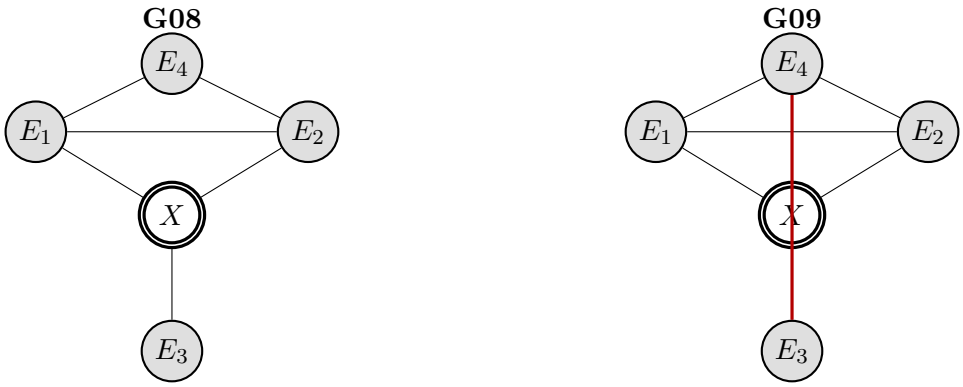


图 6: 用于 Figure 4 的 equal-local 图对。两图的局部邻域完全相同，唯一差异是 G09 多了一条远端边 $E_3$–$E_4$。

# 6 结论

本分析完整满足 TODO-2 的 3 条成功标准：

1. **Q1 成功**。 17 张 5 节点图中有 16 张在 high evidence 下呈现显著结构分离，说明最小图集已经足以产生可分离预测；无需扩展到 6 节点。

2. **Q2 成功**。 $\rho = 0, 0.25, 0.5, 0.75, 1$ 构成的连续谱在完整图集上依然稳定、单调、可解释。

3. **equal-local 判别逻辑成功**。 至少存在一对图满足 $\tilde{b}_0^A = \tilde{b}_0^B$ 但 $\tilde{b}_1^A \neq \tilde{b}_1^B$，而且分离量非常大。

设计层面的实质性结论是：**conflicting evidence 确实优于 uniform evidence**；进一步地，若把 conflicting 做成按 rooted graph 自适应优化的刺激设计，其总 pairwise separability 比 uniform 提高 3.74 倍，是后续 human experiment 最合适的 5 节点 Phase-1 模拟基线。

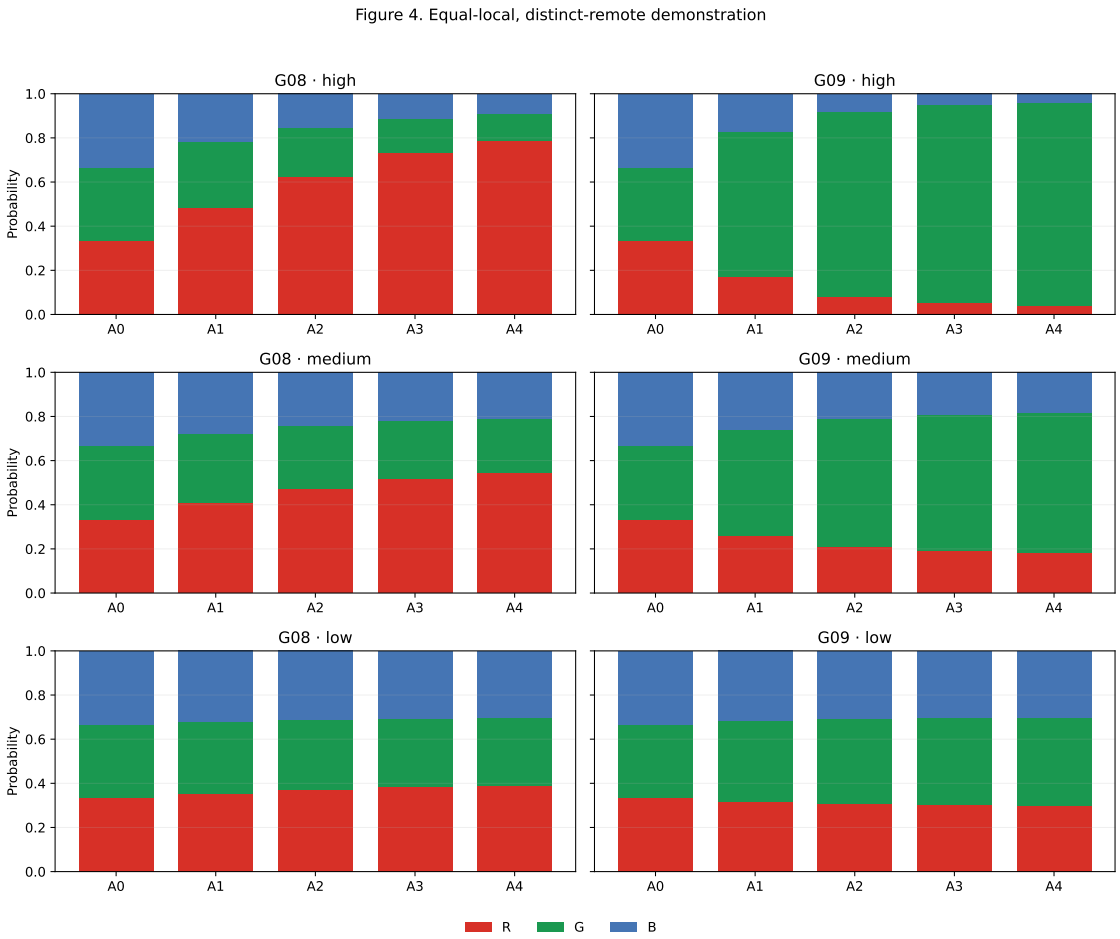


图 7: Figure 4. equal-local 图对的完整预测分布。每个小图都把 5 个代理的 $(p_R, p_G, p_B)$ 画成堆叠条形图。$A_0$ 在两图上完全一致，而高 $\rho$ 代理随远端结构出现强分离。